Proyecto 1 – Etapa 1

Entendimiento del negocio y enfoque analítico Clasificación de noticias falsas con Machine Learning

Universidad de los Andes, Colombia Materia: Inteligencia de Negocios

Estudiantes:

Tomas Alberto Rodríguez Peña Andrés Caballero Adriana Sofía Rozo Cepeda

Introducción

El auge de las noticias falsas en política ha generado un impacto significativo a nivel nacional e internacional. Estas noticias pueden influir en elecciones, polarizar sociedades y debilitar la confianza en las instituciones democráticas. A nivel internacional, pueden generar tensiones diplomáticas y ser utilizadas como herramientas de desestabilización por diversos actores políticos.

Con el objetivo de abordar esta problemática, un grupo de académicos ha recolectado un conjunto de datos que contiene noticias de varios periódicos en línea, enriquecido con ejemplos de noticias falsas. Este conjunto de datos nos servirá como base para la aplicación de **técnicas de analítica de textos** con el fin de detectar patrones y construir modelos de clasificación automática.

Generalidades

Objetivos y Criterios de Éxito

El problema descrito en la introducción demuestra que **detectar y mitigar la propagación de noticias falsas** mediante herramientas automatizadas de aprendizaje automático representa una gran oportunidad para fortalecer la calidad del debate público y la toma de decisiones informadas. Por este motivo el **objetivo principal** de este proyecto es desarrollar un sistema basado en **analítica de textos y aprendizaje automático** que permita identificar noticias falsas con un alto grado de precisión.

Para lograr lo anterior, planteamos los siguientes subobjetivos.

- 1. Construir y evaluar modelos de aprendizaje automático para clasificar noticias como falsas o verdaderas.
- 2. Identificar patrones y palabras clave que caracterizan las noticias falsas en Colombia.
- 3. Automatizar el proceso de detección para facilitar su integración en plataformas de verificación de información.

Ahora bien, el **éxito** del proyecto se medirá con la **precisión y recall** del modelo de detección al lograr un F1-score superior al 85%. Por otra parte, que exista una reducción de la desinformación en plataformas.

Organización y Rol Beneficiado

Dado que la detección de noticias falsas contribuye a una mejor calidad informativa, hemos identificado que el principal beneficiario de este proyecto es la sociedad en general.

De manera más específica, las organizaciones que pueden aprovechar esta solución incluyen los **medios de comunicación y plataformas digitales (redes sociales)**, que podrán incorporar esta herramienta en sus sistemas de verificación de contenido y, por otra parte, las **entidades gubernamentales**, que podrán utilizar los hallazgos para diseñar estrategias de regulación y alfabetización digital.

Mapa de Actores:

Rol dentro de la empresa	Tipo de Actor	Beneficiario	Riesgo
Científico de Datos	Interno	Desarrolla el modelo de detección de noticias falsas	Sesgo en los datos que afecte la precisión del modelo
Ingeniero de Datos	Interno	Automatiza la implementación del modelo para su uso continuo	Errores en la automatización que generen falsos positivos/negativos
Periodista-Verificador de Datos	Externo	Usa la herramienta para verificar la veracidad de noticias	Dependencia excesiva en la herramienta sin validaciones adicionales
Regulador Gubernamental	Externo	Toma decisiones basadas en la calidad de la información pública	Mal uso de los resultados para censura o manipulación política
Consumidor de Noticias	Externo	Recibe información verificada y evita ser engañado	Falsa sensación de seguridad al confiar solo en la herramienta

2. Impacto y Enfoque Analítico

Como lo hemos mencionado, la implementación de un sistema automatizado de detección de noticias falsas en Colombia es una oportunidad valiosa. Lo anterior es porque además de reducir la desinformación en periodos electorales y debates públicos, puede fortalecer la confianza en los medios de comunicación y en las instituciones. Lo anterior implica mejorar la toma de decisiones informadas tanto a nivel ciudadano como gubernamental y evitar pánico colectivo al recibir una información tergiversada.

Para lograr estos objetivos, se aplicará un enfoque estructurado basado en **aprendizaje automático** con las siguientes características:

Categoría del	Tipo de Aprendizaje	Tasa de	Técnicas y	
Análisis		Aprendizaje	algoritmos	
Análisis	Supervisado, dado	Clasificación, ya	Random Forest,	
predictivo , ya	que se cuenta con un	que el objetivo es	Decision Tree and	
que se busca	dataset etiquetado	asignar cada noticia	Logistic Regression	
clasificar	donde las noticias	a una de dos		
automáticamente	están previamente	categorías (falsa o		
noticias como	categorizadas.	verdadera).		
verdaderas o				
falsas.				